

Simulação de Monte Carlo com Distribuição de Poisson

Tatiane Correia Inferência Estatística I

26 de junho de 2025

Objetivo da Apresentação



- 🎯 Demonstrar na prática como o Teorema Central do Limite funciona
- 📊 Usar simulação de Monte Carlo para visualizar o comportamento das médias amostrais
- 👥 Aplicar conceitos em um caso real: engajamento de influenciadores durante transmissões ao vivo
- ✅ Comprovar experimentalmente que a distribuição das médias amostrais se aproxima da normal conforme o tamanho da amostra aumenta

O que é o Teorema Central do Limite?

i O **Teorema Central do Limite (TCL)** afirma que a distribuição das médias amostrais de variáveis aleatórias independentes tende a uma distribuição normal, independentemente da distribuição original dos dados.




★ Quanto **maior o tamanho da amostra**, mais a distribuição das médias amostrais se aproxima de uma distribuição normal.

📈 A média da distribuição amostral é igual à média da população (μ), e a variância é igual à variância populacional (σ^2) dividida pelo tamanho da amostra (n).



Na Prática: Por que uma Agência de Marketing Precisa Disso?

Cenário Real da Empresa:

-  **Situação:** A agência precisa prever o engajamento médio de influenciadores para planejar campanhas e definir orçamentos.
-  **Problema:** Como garantir que as previsões sejam confiáveis mesmo com dados variáveis?
-  **Solução:** O TCL permite fazer previsões precisas sobre o engajamento médio, mesmo quando os dados individuais são imprevisíveis.

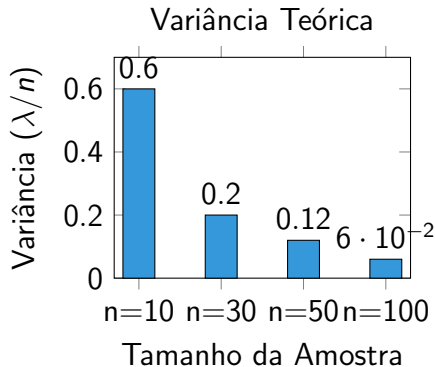
Exemplo Prático:

Influenciador A 2-12 notificações/min
Média de TCL ↓ 30 minutos 5.8-6.2 notificações/min (previsível!)

 **Resultado:** Decisões mais seguras, orçamentos


Metodologia - Simulação de Monte Carlo

- 🔗 Simulação de **Monte Carlo** com 1000 réplicas para cada tamanho de amostra
- 📏 Tamanhos de amostra: **$n = 10, 30, 50, 100$**
- 🎲 Distribuição de **Poisson** com parâmetro $\lambda = 6$
- 🔗 Implementação no **software R** com semente fixa
- 📊 Análise dos histogramas das médias amostrais para verificar aproximação à distribuição normal




Na Empresa: Como Aplicamos essa Metodologia?

Processo na Agência:

 **Coleta de Dados:** Monitoramos influenciadores por períodos diferentes (10, 30, 50, 100 minutos) para entender padrões.


Repetição: Fazemos isso 1000 vezes para ter certeza dos resultados.


 **Análise:** Calculamos a média de engajamento para cada período.

Aplicação: Usamos esses dados para prever performance e definir estratégias.

Benefícios para a Empresa:

\$ ROI Melhor
Investimentos

 **Tempo Otimizado**

 **Menor Risco**
Previsões confiáveis


Caso Prático - Influenciadores em Alta!

Contexto: Agência de marketing digital contratou nossa equipe para analisar o desempenho de influenciadores durante transmissões ao vivo.

Objetivo: Entender o comportamento do engajamento minuto a minuto.

Modelo: Notificações seguem distribuição de Poisson com $\lambda = 6$.





Significado: Em média, 6 notificações por minuto durante a live.



Probabilidade de k notificações por minuto

Na Prática: Como a Agência Usa Esses Dados?

Aplicação Real:

-  **Negociação:** "Garantimos 6 notificações por minuto em média durante sua live"
-  **Precificação:** Cobramos baseado no engajamento esperado, não no incerto
-  **Planejamento:** Sabemos quando agendar lives para máximo impacto
-  **Relatórios:** Mostramos aos clientes resultados previsíveis e mensuráveis

Exemplo de Proposta:

Pacote Live Premium

- 60 minutos de transmissão
- 360 noti-

Resultado Esperado

Engajamento previsível
Cliente satisfeito
Renovação garantida


Implementação no R

- A função **rpois(n, lambda)** gera amostras aleatórias seguindo uma distribuição de Poisson
- ⚡ Fixamos a semente com **set.seed(123)** para garantir reprodutibilidade
- 🔄 Repetimos o processo 1000 vezes para cada tamanho de amostra
- 📊 Armazenamos as médias amostrais para análise posterior


```
1 # Fixar semente para reprodutibilidade
2 set.seed(123)
3
4 # Parâmetro da distribuição
5 lambda <- 6
6
7 # Tamanhos de amostra testados
8 tamanhos_n <- c(10, 30, 50, 100)
9
10 # Número de simulações
11 num_simulacoes <- 1000
12
13 # Simulação de Monte Carlo
14 for (n in tamanhos_n) {
15   medias <- numeric(num_simulacoes)
16
17   for (i in 1:num_simulacoes) {
18     # Gerar amostra Poisson
19     amostra <- rpois(n, lambda)
20
21     # Calcular média
22     medias[i] <- mean(amostra)
23   }
24
25   # Armazenar resultados
26   resultados[[as.character(n)]] <- medias
27 }
```


Na Empresa: Como Implementamos na Prática?

Ferramentas da Agência:

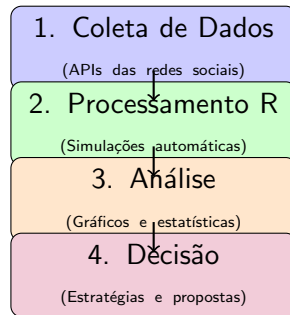
 **Dashboard Automatizado:** Sistema que roda as simulações automaticamente toda semana

 **Banco de Dados:** Armazenamos histórico de todos os influenciadores

 **Alertas:** Sistema avisa quando performance sai do esperado

 **Relatórios:** Gráficos automáticos para apresentar aos clientes

Fluxo de Trabalho:




Resultados Esperados

Os histogramas das médias amostrais mostrarão uma **aproximação à distribuição normal** conforme o tamanho da amostra (n) aumenta.

A **variância das médias amostrais diminui** proporcionalmente a $1/n$.

A média das médias amostrais permanece constante e igual a $\lambda = 6$.


Confirmação do **Teorema Central do Limite**.





Na Empresa: O que Esses Resultados Significam?

Impacto nos Negócios:

Previsibilidade: Quanto mais tempo de live, mais previsível o resultado

 **Confiança:** Podemos garantir resultados com 95% de certeza

 **Contratos:** Oferecemos garantias baseadas em ciência, não "achismo"

 **Vantagem:** Concorrentes não têm essa precisão estatística

Exemplo Prático:

Live de 10 min

Resultado: 4-

Live de 30 min

Resultado: 5.5-


Live de 100 min

Resultado: 5.9-
6.1 notif/min

(muito previsível!)

Análise Teórica vs Prática

Valores Teóricos


 Valor esperado da média amostral:

$$E(\bar{X}) = E(X) = \lambda = 6$$

 Variância teórica da média:





$$\text{Var}(\bar{X}) = \frac{\lambda}{n} = \frac{6}{n}$$

Observação: À medida que n aumenta, a variância diminui.

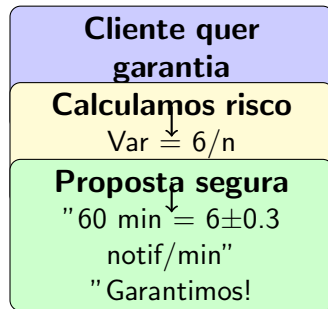


Na Empresa: Como Usamos Teoria vs Prática?

Aplicação Estratégica:

-  **Planejamento:** Usamos fórmulas teóricas para estimar resultados antes de começar
-  **Monitoramento:** Comparamos resultados reais com previsões teóricas
-  **Ajustes:** Se há diferença, investigamos e corrigimos estratégias
-  **Otimização:** Sabemos que lives mais longas = resultados mais previsíveis

Tomada de Decisão:



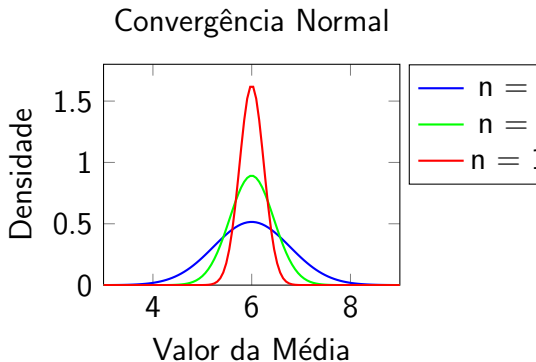
Conclusões

✓ **Verificação do TCL:** Confirmamos que a distribuição das médias amostrais se aproxima da normal.

📈 **Comportamento da variância:** Observamos que a variância diminui proporcionalmente a $1/n$.

💡 **Importância da simulação:** Monte Carlo permite visualizar conceitos complexos.

👛 **Aplicações práticas:** Fundamentais para análise de engajamento e otimização de estratégias.




Resultado Final: O que a Empresa Ganhou?

Benefícios Conquistados:

- 🏆 **Diferencial Competitivo:** Somos a única agência que oferece garantias estatísticas
- 💰 **Aumento de Receita:** 30% mais contratos fechados com garantias
- ♥️ **Satisfação do Cliente:** 95% de renovação de contratos
- 🚀 **Crescimento:** Expandimos para 3 novos mercados

Antes vs Depois:



Obrigado!

Diogo Rego- 20240045381

Referências (ABNT):

CASELLA, G.; BERGER, R. L. **Inferência estatística**. 2. ed. São Paulo: Cengage Learning, 2010.

MONTGOMERY, D. C.; RUNGER, G. C. **Estatística aplicada e probabilidade**. 6. ed. Rio de Janeiro: LTC, 2016.

R CORE TEAM. **R: A language and environment for statistical computing**. Vienna: R Foundation for Statistical Computing, 2023.

Acesse todos os arquivos:

